Франкенштейн

Или о том, как мы город собирали

Группа 2, третья майская школа по статистике

22 февраля 2026

Бизнес задача

Хотим понять, будет ли прибыльным открытие нового отделения в Волгограде.

Бизнес задача

У нас есть:

- Данные об использовании товаров в Волгограде и еще 19 городах до и после открытия отделения,

Бизнес задача

У нас есть:

- Данные об использовании товаров в Волгограде и еще 19 городах до и после открытия отделения,
- Данные об этих 20 городах, не относящиеся к банку.

Бизнес задача

Мы хотим:

- Используя все данные, создать город-контроль из других городов (близнец Волгограда),

Бизнес задача

Мы хотим:

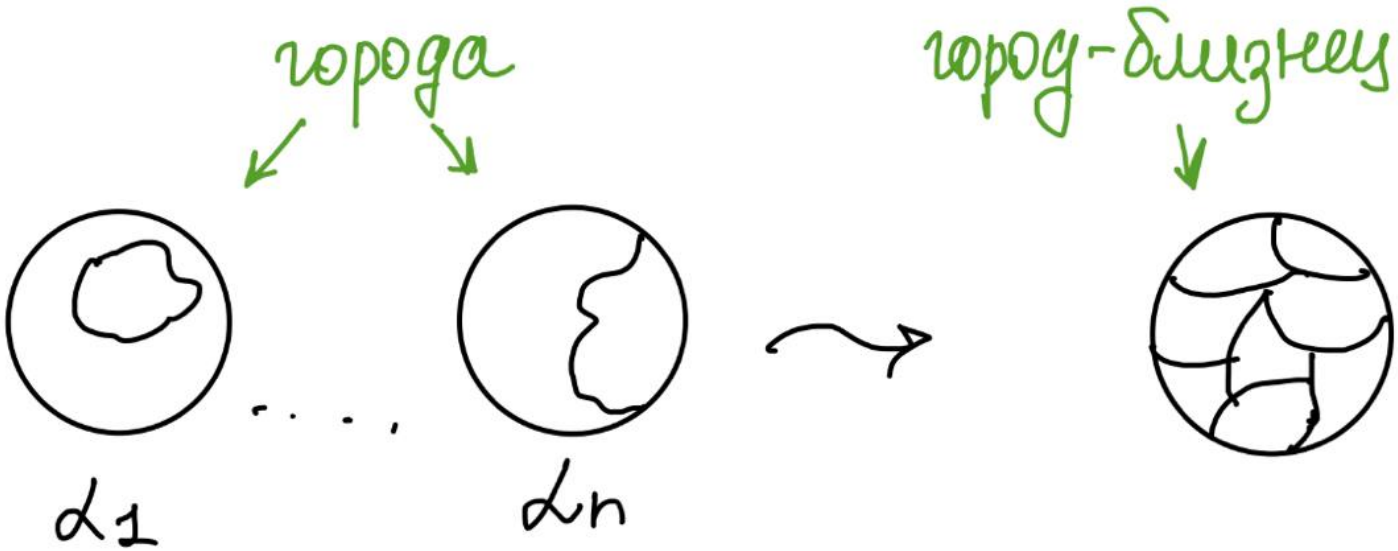
- Используя все данные, создать город-контроль из других городов (близнец Волгограда),
- Сравнить Волгоград после открытия отделения с близнецом (эффект),

Бизнес задача

Мы хотим:

- Используя все данные, создать город-контроль из других городов (близнец Волгограда),
- Сравнить Волгоград после открытия отделения с близнецом (эффект),
- Оценить эффект и его значимость.

Бизнес задача



План решения

1. Строим математическую модель,

План решения

1. Строим математическую модель,
2. Решение математической задачи,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,
5. Стандартизируем характеристики,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,
5. Стандартизируем характеристики,
6. Выкидываем лишние города, оставляем 5 городов,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,
5. Стандартизируем характеристики,
6. Выкидываем лишние города, оставляем 5 городов,
7. Строим регрессию,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,
5. Стандартизируем характеристики,
6. Выкидываем лишние города, оставляем 5 городов,
7. Строим регрессию,
8. Находим эффект,

План решения

1. Строим математическую модель,
2. Решение математической задачи,
3. Находим распределение эффекта,
4. Выбираем избранные характеристики,
5. Стандартизируем характеристики,
6. Выкидываем лишние города, оставляем 5 городов,
7. Строим регрессию,
8. Находим эффект,
9. Получаем значимость эффекта.

Убираем характеристики

- По смыслу не важны,

Убираем характеристики

- По смыслу не важны,
- По смыслу отвечает за то же,

Убираем характеристики

- По смыслу не важны,
- По смыслу отвечает за то же,
- Сильно коррелирует с остальными,

Убираем характеристики

- По смыслу не важны,
- По смыслу отвечает за то же,
- Сильно коррелирует с остальными,
- Не выйдет их стандартизовать (в единицах на человека).

Стандартизируем данные

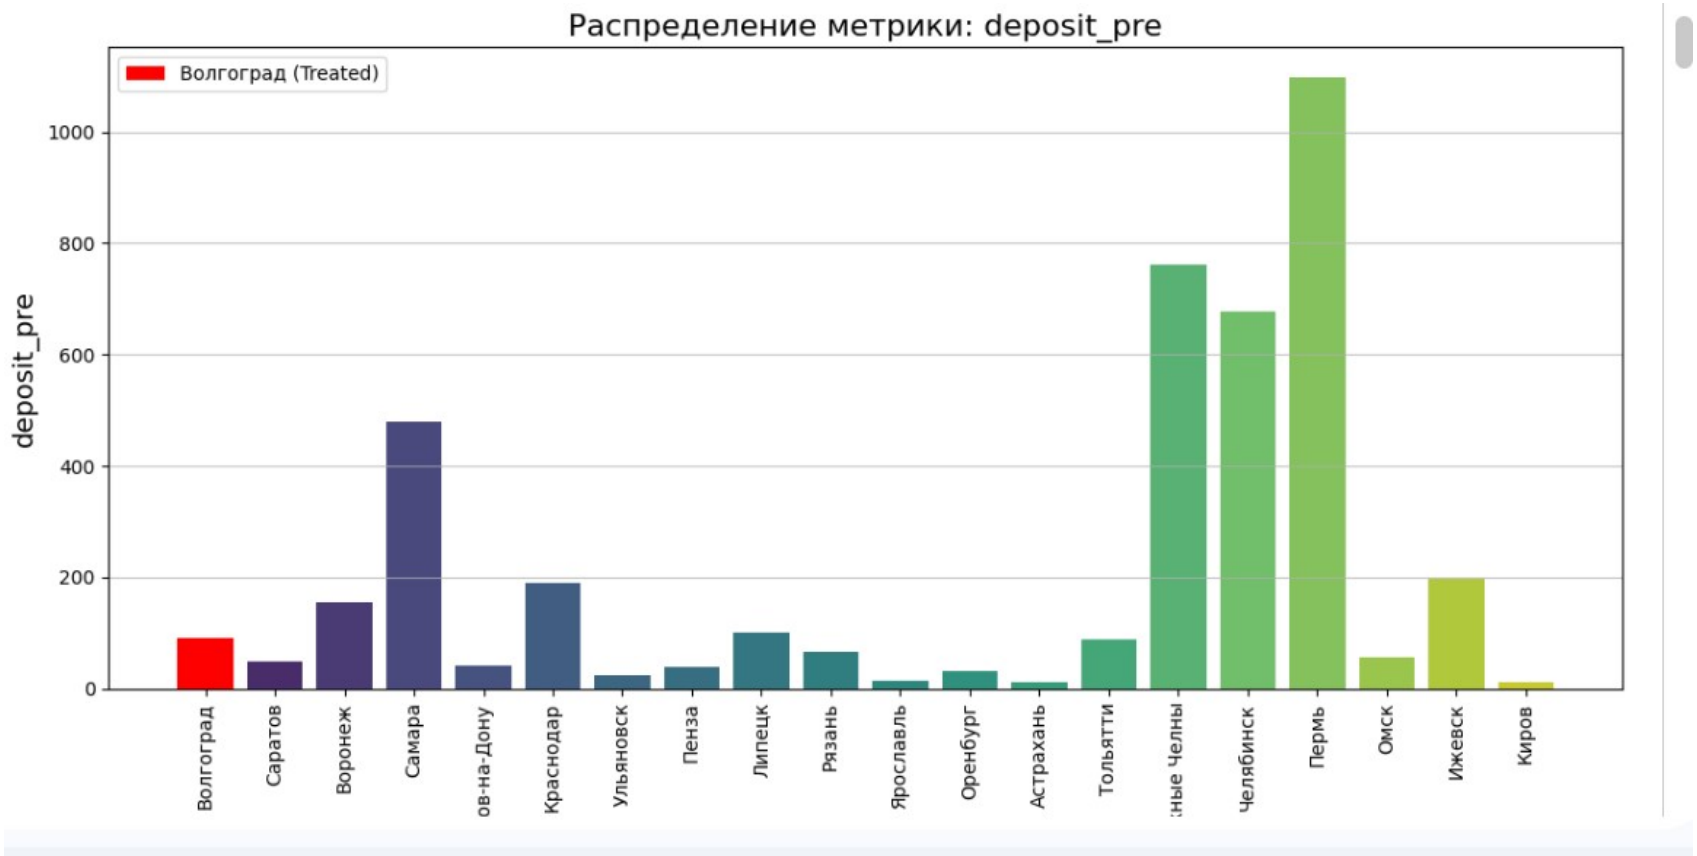
- Приводим их в вид доля или единица на население

Стандартизируем данные

- Приводим их в вид доля или единица на население
- Стандартизируем данные

Выкидываем лишние города, оставляем 5 городов

Убираем те, что сильно отличаются от Волгограда по ключевым характеристикам



Строим математическую модель

- $\vec{Y}_{B,\text{pre}}$ - показатели Волгограда на предпериоде.

Строим математическую модель

- $\vec{Y}_{B,\text{pre}}$ - показатели Волгограда на предпериоде.
- $\mathbb{X}_{pre}$- матрица предикторов из оставшихся городов и признаков на предпериоде.

Строим математическую модель

- $\vec{Y}_{B,\text{pre}}$ - показатели Волгограда на предпериоде.
- $\mathbb{X}_{pre}$- матрица предикторов из оставшихся городов и признаков на предпериоде.
- $\vec{Y}_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$

Строим математическую модель

- $\vec{Y}_{B,\text{pre}}$ - показатели Волгограда на предпериоде.
- $\mathbb{X}_{pre}$- матрица предикторов из оставшихся городов и признаков на предпериоде.
- $\vec{Y}_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- $\vec{Y}_{\Phi,\text{pre}} = \mathbb{X}_{pre}\hat{\vec{\alpha}}$

Строим математическую модель

- $\vec{Y}_{B,\text{pre}}$ - показатели Волгограда на предпериоде.
- $\mathbb{X}_{pre}$- матрица предикторов из оставшихся городов и признаков на предпериоде.
- $\vec{Y}_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- $\vec{Y}_{\Phi,\text{pre}} = \mathbb{X}_{pre}\vec{\hat{\alpha}}$
- $\sum_{i=1}^{n} \alpha_i = 1$ и $\alpha \geqslant 0$

Строим математическую модель

- $\vec{Y}_{B,\text{post}}$ - показатели Волгограда на постпериоде.

Строим математическую модель

- $\vec{Y}_{B,\text{post}}$ - показатели Волгограда на постпериоде.
- $\mathbb{X}_{post}$- матрица предикторов из оставшихся городов и признаков на предпериоде.

Строим математическую модель

- $\vec{Y}_{B,\text{post}}$ - показатели Волгограда на постпериоде.
- $\mathbb{X}_{post}$- матрица предикторов из оставшихся городов и признаков на предпериоде.
- $\vec{Y}_{\Phi,\text{post}} = \mathbb{X}_{post}\vec{\hat{\alpha}}$

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon},\ \vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:
  1. Адекватность

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:
  1. Адекватность
  2. Гомоскедастичность (отнормировали на выборочную дисперсию)

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:
  1. Адекватность
  2. Гомоскедастичность (отнормировали на выборочную дисперсию)
  3. Некоррелировнность остатков

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon}$, $\vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:
  1. Адекватность
  2. Гомоскедастичность (отнормировали на выборочную дисперсию)
  3. Некоррелировнность остатков
  4. Нормальность остатков
- $\vec{\hat{\alpha}} \sim \mathcal{N}(\vec{\alpha}, \sigma^2(\mathbb{X}_{pre}^T \mathbb{X}_{pre})^{-1})$

Решение математической задачи

- $Y_{B,\text{pre}} = \mathbb{X}_{pre}\vec{\alpha} + \vec{\varepsilon},\ \vec{\varepsilon} \sim \mathcal{N}(0, \sigma^2 E)$
- Все предпосылки для линейной регрессии выполнены:
  1. Адекватность
  2. Гомоскедастичность (отнормировали на выборочную дисперсию)
  3. Некоррелировнность остатков
  4. Нормальность остатков
- $\vec{\hat{\alpha}} \sim \mathcal{N}(\vec{\alpha}, \sigma^2(\mathbb{X}_{pre}^T \mathbb{X}_{pre})^{-1})$
- $\vec{Y}_{\Phi,\text{post}} = \mathbb{X}_{post}\vec{\hat{\alpha}} \sim \mathcal{N}(\mathbb{X}_{post}\vec{\alpha}, \sigma^2 \mathbb{X}_{post}(\mathbb{X}_{pre}^T \mathbb{X}_{pre})^{-1}\mathbb{X}_{post}^T)$

Критерий

- Главное допущение - $\vec{Y}_{\mathrm{B,post}}$- константа.

Критерий

- Главное допущение - $\vec{Y}_{\text{B,post}}$- константа.
- $H_0 : E\vec{Y}_{\Phi,\text{post}} = \vec{Y}_{\text{B,post}}$

Критерий

- Главное допущение - $\vec{Y}_{\text{B,post}}$- константа.
- $H_0 : E\vec{Y}_{\Phi,\text{post}} = \vec{Y}_{\text{B,post}}$
- 7 правосторонних альтернатив по каждой из координат,

Критерий

- Главное допущение - $\vec{Y}_{\text{B,post}}$- константа.
- $H_0 : E\vec{Y}_{\Phi,\text{post}} = \vec{Y}_{\text{B,post}}$
- 7 правосторонних альтернатив по каждой из координат,
- Используем поправку бонферрони,
- Используем t-test

Строим регрессию для Волгограда

Волгоград был приближен следующими городами: Воронеж, Ростов-на-Дону, Омск, Саратов, Ярославль
со следующими коэффициентами: 0.16515184, 0.14228857, 0.30199763, 0.04368591, 0.34687604.

Сравнение всех использованных метрик для 'Синтетического города' и 'Волгограда' (нестандартизированные значения):

Метрика	Синтетический город (нестанд.)	Волгоград (нестанд.)
MortgageVolume_per_capita	0.417542	0.333699
Age_60_plus	0.212402	0.245349
Density_per_km2	0.000893	0.000967
RetailTurnoverPerCapita	289803.490171	277594.151526
PovertyRate	0.157330	0.124689
IncomePerCapita	33200.738261	30000.000000
HousingPerCapita_m2	21.912567	24.972079
MigrationRate_per_1000	0.000659	0.001012
debit_pre	0.001194	0.001155
credit_pre	0.000137	0.000105
loan_pre	0.000051	0.000051
invest_pre	0.000030	0.000027
savings_pre	0.000108	0.000086
deposit_pre	0.000060	0.000089
premium_pre	0.000039	0.000041

Строим регрессию для другогих городов (Валидация для Воронежа)

```
Data standardized without PCA.
Top 4 cities most similar to 'Воронеж':
['Омск', 'Ростов-на-Дону', 'Ярославль', 'Астрахань']
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retail
Коэффициенты a_constrained:
[0.21447175 0.1357599  0.07531559 0.57445276]
Было ли строгое равенство суммы коэффициентов 1?  True
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retail
Сравнение метрик 'Синтетический город' и Воронеж:
          Синтетический город   Воронеж  Процентная Дельта
Метрика
invest_post              0.000019  0.000029          32.684857
loan_post                0.000059  0.000035          70.515166
debit_post               0.001333  0.001088          22.526486
credit_post              0.000164  0.000059         180.427860
savings_post             0.000117  0.000148          21.085012
deposit_post             0.000043  0.000139          69.139639
premium_post             0.000032  0.000032           0.890765
```

Строим регрессию для другогих городов (Валидация для Рязани)

```
Top 4 cities most similar to 'Рязань':
['Астрахань', 'Пенза', 'Ульяновск', 'Липецк']
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retai
Коэффициенты a_constrained:
[0.07431162 0.08774726 0.         0.83794112]
Было ли строгое равенство суммы коэффициентов 1?  True
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retai
Сравнение метрик 'Синтетический город' и Рязань:
            Синтетический город    Рязань  Процентная Дельта
Метрика
invest_post                0.000032  0.000060          46.393575
loan_post                  0.000101  0.000152          33.834863
debit_post                 0.000826  0.001311          37.031821
credit_post                0.000256  0.000408          37.294972
savings_post               0.000290  0.000293           0.871436
deposit_post               0.000044  0.000139          68.456734
premium_post               0.000028  0.000064          56.304143
Data standardized without PCA.
```

Строим регрессию для другогих городов (Валидация для Омска)

```
Top 4 cities most similar to 'Омск':
['Воронеж', 'Ярославль', 'Саратов', 'Ростов-на-Дону']
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retail
Коэффициенты a_constrained:
[0.         0.44680573 0.25076181 0.30243246]
Было ли строгое равенство суммы коэффициентов 1?  True
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'Retail
Сравнение метрик 'Синтетический город' и Омск:
            Синтетический город      Омск  Процентная Дельта
Метрика
invest_post                0.000024  0.000014          78.067067
loan_post                  0.000035  0.000064          44.902238
debit_post                 0.001018  0.001552          34.380644
credit_post                0.000092  0.000164          44.114847
savings_post               0.000110  0.000114           3.769167
deposit_post               0.000081  0.000048          68.663649
premium_post               0.000031  0.000030           3.626117
```

Строим регрессию для другогих городов (Валидация для Ростова-на-Дону)

```
Top 4 cities most similar to 'Ростов-на-Дону':
['Воронеж', 'Омск', 'Саратов', 'Тольятти']
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'RetailTur
Коэффициенты a_constrained:
[0.37852547 0.13115898 0.20640016 0.28391538]
Было ли строгое равенство суммы коэффициентов 1?  True
Столбцы ['MortgageVolume_per_capita', 'Age_60_plus', 'Density_per_km2', 'RetailTur
Сравнение метрик 'Синтетический город' и Ростов-на-Дону:
            Синтетический город  Ростов-на-Дону  Процентная Дельта
Метрика
invest_post                0.000062       0.000041          50.134858
loan_post                  0.000096       0.000048          98.838497
debit_post                 0.000908       0.001301          30.233938
credit_post                0.000331       0.000178          85.412387
savings_post               0.000138       0.000066         107.924067
deposit_post               0.000081       0.000035         130.674903
premium_post               0.000082       0.000048          71.221147
Data standardized without PCA.
```

Получаем значимость эффекта

Полученный результат:

Metric	Actual Post	Synthetic Post	Difference	SE Synthetic Post	t-statistic	p-value	Significant Effect (p < 0.05)?
invest_post	0.000026	0.000043	-0.000017	0.001536	-0.010981	0.991478	No
loan_post	0.000049	0.000041	0.000009	0.000859	0.009897	0.992319	No
debit_post	0.001276	0.000875	0.000402	0.024761	0.016227	0.987407	No
credit_post	0.000137	0.000088	0.000050	0.004435	0.011192	0.991314	No
savings_post	0.000114	0.000085	0.000028	0.000561	0.050635	0.960722	No
deposit_post	0.000076	0.000054	0.000022	0.002398	0.009104	0.992934	No
premium_post	0.000054	0.000017	0.000037	0.000628	0.059066	0.954190	No

Причина

Ошибка в том, что в коде мы неправильно нормировали в коде.
В следующий раз исправимся))))

Что можно было, но мы не успели

- использовать CUPED,

Что можно было, но мы не успели

- использовать CUPED,
- Убрать допущение о константности,

Что можно было, но мы не успели

- использовать CUPED,
- Убрать допущение о константности,
- Улучшить отбор городов и признаков.